附录

A. 大模型提示词

1. 大模型作文评分提示词（零样本学习）

系统指令：你是一位经验丰富的汉语写作教学专家，尤其擅长针对母语非汉语的学习者的教学。

用户指令：请阅读并评估以下命题作文。
作文题目："{}"
作文内容："{}"
请根据以下 12 级评分标准为作文评分。评分等级从 1 分到 12 分，具体标准如下：
"{HSK 评分标准内容}"
请以 JSON 格式返回评分结果，仅包含一个键值对："score"，值为 1 到 12 之间的整数分数。

2. 大模型作文评分提示词（小样本学习）

系统指令: 你是一位经验丰富的汉语写作教学专家，尤其擅长针对母语非汉语的学习者的教学。

用户指令: 首先展示 5 篇示例作文：
示例作文 1。题目为 "{}"，得分 "{}":
"{}"
……
示例作文 5。题目为 "{}"，得分 "{}":
"{}"
现在请你参考以上示例作文，为以下作文评分。
作文题目："{}"
作文内容："{}"
评分时请结合下面的评分标准，评分等级从 1 分到 12 分，具体标准如下：
"{HSK 评分标准内容}"
请以 JSON 格式返回评分结果，仅包含一个键值对："score"，值为 1 到 12 之间的整数分数。

3. 大模型作文评分提示词（语言复杂化）

系统指令: 你是一位经验丰富的汉语写作教学专家，尤其擅长针对母语非汉语的学习者的教学。

用户指令: 请按照以下要求优化所提供的作文：
1. 提升词汇水平：
- 适当引入高等级词汇，替换基础常用词
- 增加成语和固定搭配的使用
- 注意词语搭配的地道性和准确性

避免词语重复，使用同义词丰富表达
2. 改进句式结构：
- 合理运用复句，包括并列句、转折句、因果句、条件句等
- 合理运用关联词语的使用（"不但... 而且..."、
- "既... 又..."、
- 适当使用补语结构（结果补语、趋向补语、可能补语等）
- 恰当运用较复杂的语法点（把字句、被字句、"是... 的" 句式等）

3. 保持原则：
- 保持原文的核心思想和主要内容不变
- 维持原有段落结构和文章长度
- 确保表达清晰自然，符合汉语习惯

输入作文："{}"
请以 JSON 格式返回修改后的作文：
` {"output_essay": "..."}

4. 大模型作文评分提示词（语言简化）

系统指令: 你是一位经验丰富的汉语写作教学专家，尤其擅长针对母语非汉语的学习者的教学。

用户指令: 请按照以下要求简化所提供的作文：
1. 简化词汇：
- 用基础常用词汇替换高级词汇
- 将成语和书面用语改写为口语化表达
- 减少同义词的使用，优先选择最常用词
- 避免使用专业术语和深奥词语，确保词语简单易懂
2. 简化句式：
- 将复句拆分为简单句
- 减少关联词语的使用（如："不但... 而且..."、
- "因为... 所以..."）
- 减少修饰成分，保留核心表达，尽量使用"主谓宾" 的基本句式
- 避免使用复杂的语法结构（如长定语、复杂补语）
3. 保持原则：
- 保持原文的核心思想和主要内容不变
- 维持原有段落结构和文章长度
- 确保表达清晰自然，符合汉语习惯

输入作文："{}"
请以 JSON 格式返回修改后的作文：
` {"output_essay": "..."}

5. 大模型作文反馈提示词

	系统指令: 你是一位经验丰富的汉语写作教学专家，尤其擅长针对母语非汉语的学习者的教学。
第一轮（评分）	**用户指令**: 首先展示 5 篇示例作文： …… 请以 JSON 格式返回评分结果，仅包含一个键值对："score"，值为 1 到 12 之间的整数分数。
	模型回复：{"score": 6}
第二轮（反馈）	**用户指令**：请针对以下几个方面，对这篇作文提供全面且有建设性的反馈: 1. 语言准确性: …… 2. 语言复杂性: …… 3. 篇章组织水平: …… 请以 JSON 格式输出反馈，包含以下字段::

	` json { “语言准确性反馈”: “”, “语言复杂性反馈”: “”, “篇章组织水平反馈”: “”, } ` 如有可能，请引用原文中的具体句子来支持你的反馈。

6. 大模型作文反馈提示词（分别用于记叙文与议论文生成）

记叙文 反馈生成	<u>用户指令</u>：请针对以下几个方面，对这篇作文提供全面且有建设性的反馈: 1. 语言准确性: • 汉字：评价汉字使用情况，是否存在别字、多字、漏字等现象； • 词汇：评价词汇使用情况，是否存在词汇使用错误、词汇冗余、词汇缺漏等现象。 • 标点：评价标点使用情况，指出标点使用不当之处，如流水句、书名号-引号混淆等； • 语法：评价语法使用情况，包括句法结构是否正确、语言是否流畅、语序是否恰当，虚词（介词、连词、助词等）是否使用规范等。 2. 语言复杂性: • 词汇：评价词语使用情况，包括词汇量是否丰富、是否恰当地选择词语、使用成语和固定搭配等； • 句式：评价句式使用情况，包括简单句与复句（如并列、转折、因果等）的运用情况，以及句式结构变化（如长短句搭配、主动被动交替、成分省略等）。 3. 篇章组织水平: • 评价文章的记叙结构是否完整。开头是否交代背景、时间、人物等要素，中间是否充分展现人物活动和事件过程，结尾是否对人物或事件有恰当的升华或感悟； • 评价文章的记叙脉络是否清晰。人物行为和事件发展是否前后呼应、符合内在逻辑。是否通过自然过渡（如时间提示、空间转换、承启句等）保持叙述流畅，并推动事件发展。 请以 JSON 格式输出反馈，包含以下字段:: ` json { “语言准确性反馈”: “”, “语言复杂性反馈”: “”, “篇章组织水平反馈”: “”, } ` 如有可能，请引用原文中的具体句子来支持你的反馈。
议论文 反馈生成	<u>用户指令</u>：请针对以下几个方面，对这篇作文提供全面且有建设性的反馈: 1. 语言准确性: • 汉字：评价汉字使用情况，是否存在别字、多字、漏字等现象；

	• 词汇：评价词汇使用情况，是否存在词汇使用错误、词汇冗余、词汇缺漏等现象。 • 标点：评价标点使用情况，指出标点使用不当之处，如流水句、书名号-引号混淆等； • 语法：评价语法使用情况，包括句法结构是否正确、语言是否流畅、语序是否恰当，虚词（介词、连词、助词等）是否使用规范等。 2. 语言复杂性: • 词汇：评价词语使用情况，包括词汇量是否丰富、是否恰当地选择词语、使用成语和固定搭配等； • 句式：评价句式使用情况，包括简单句与复句（如并列、转折、因果等）的运用情况，以及句式结构变化（如长短句搭配、主动被动交替、成分省略等）。 3. 篇章组织水平: • 评价作文的整体结构是否完整。开头是否点明主题，正文是否充分展开论述，结尾是否总结到位； • 评价作文中条理是否清晰。句子的连接是否顺畅、段落之间的过渡是否自然、是否使用恰当的关联词、过渡语等表达清晰的逻辑关系。 请以 JSON 格式输出反馈，包含以下字段:: ` json { “语言准确性反馈”: “”, “语言复杂性反馈”: “”, “篇章组织水平反馈”: “”, } ` 如有可能，请引用原文中的具体句子来支持你的反馈。

B. 反事实干预构造方式

1. 语言准确性干预构造方式

（1）错误校正（+）：直接采用 HSK 动态作文语料库中的人工标注修正其中的字、词、句、篇、标点等偏误；

（2）书写错误引入（–）：基于 HSK 动态作文语料库的偏误标注统计构建别字映射表，在每篇作文中随机选取 50% 的句子，并从中随机选择 30% 的汉字；若该字在映射表中存在对应别字，则按映射关系进行替换（如将“今年”替换为“令年”）；

（3）语法错误引入（–）：本研究通过向作文引入“的/地/得”错误来实现语法干预。我们基于 SpaCy 的依存句法分析并结合预定义规则，逐句识别作文中使用正确的结构助词，并将其随机替换为其余两个中的任意一个（如将“跳得高”改为“跳的高”）；若原本使用错误或句中不存在“的/地/得”，则不作修改。

（4）词序错误引入（–）：对所有经过错误校正的作文，在 50% 的句子中随机选择 30% 的词汇，记录其索引并随机交换位置。

2. 篇章组织水平干预构造方式

首先使用 SpaCy 库对作文进行分句并基于换行符识别段落结构，在此基础上施加“**段内句序重排**”（–）和“**文内句序重排**”（–）两类干预。前者保持段落边界不变，仅打乱段内句子顺序；后者则忽略段落边界打乱全文句子顺序，但保持各段落的句子数量不变。

C. 反事实样本的有效性评估

反事实干预分析的有效性在很大程度上取决于干预样本的质量。理想的干预应在目标维度上产生可测量的变化，同时尽可能保持其他语言特征不变。2.4 节所述的八种干预策略在确定性上存在差异：基于规则的干预（如别字引入、语法错误引入、词序错误引入及句序重排）效果明确，可由规则本身保证；而基于人工标注的错误校正以及基于大模型改写的语言复杂化与语言简化则存在较大的不确定性：前者的效果取决于标注者对错误的定义及其校正标准，后者则受模型指令遵循能力和文本生成质量制约。因此，本节重点评估这三类干预所生成的反事实样本是否在预期维度上产生了有效变化。

具体而言，本研究引入词汇数量、句子数量、平均句长、平均依存树深度、词汇多样性（Type-Token Ratio）、词汇复杂度[①]等六项语言学指标，并使用 Cohen's D 来度量各指标在干预前后的变化幅度。此外，本研究采用 gte-Qwen2-7B-instruct 模型[②]计算干预前后作文语义向量的余弦相似度，以衡量反事实干预对原文语义的保留程度。

图 1 展示了基于 Cohen’s D 的评估结果。对于基于人类标注的“**错误校正**”，干预后词汇复杂度明显下降。这是因为在错误修正前，许多作文中存在别字，这导致 CLRA 将某些常用词归类为了中级、高级或超纲词范畴。在错误修正后，这些常用词被正确归类到了更低等级，因此词汇复杂度显著下降。这种改动也同时导致了词汇多样性的下降；此外，错误校正后平均句长和句子数量也有所下降，这是因此错误校正前文中存在许多标点符号错误，尤以“流水句”问题最为典型。在这些错误被校正后，平均句长和句子数量有所下降。

对于“**语言复杂化**”，干预后各项语言学指标均为正效应，其中词汇复杂性和多样性提升相较于词汇数量、平均句法树深度、平均句长更显著，这表明语言复杂化对作文复杂性的提升主要体现通过使用复杂、多样的词汇实现，没有过度扩展作文内容，这符合我们对于语言复杂化干预的预期。

对于“**语言简化**”，干预后除句子数量以外，其余各项语言学指标均表现负效应，其中词汇复杂度明显下降，但词汇多样性下降并不明显，这是因为由汉语二语学习者所写的作文中，存在许多重复使用同一词汇的情况，即词汇多样性本来就较低，因此在词汇多样性上进一步简化的空间并不大。此外，平均句法树深度和平均句长也有明显下降，伴随着句子数量的减少，这意味着语言简化过程中许多长句被拆解为了较短句，这符合我们对于语言简化干预的预期。

---

① 词汇复杂度指标参考《国际中文教育中文水平等级标准》(中华人民共和国教育部等, 2021)，测量文本内中级、高级及超纲词语的词种占比，测量工具为 CLRA 中文词汇特征分析器(徐云洁, 胡韧奋, 2025)。

② gte-Qwen2-7B-instruct 模型详情见：https://huggingface.co/Alibaba-NLP/gte-Qwen2-7B-instruct

图 1 基于语言学指标的反事实干预有效性分析

D. 不符合干预预期的反馈模式

1. 语言简化干预反馈示例

这是一篇题为《关于用自然之声取代噪声的建议》的作文在错误校正和语言简化干预前后的内容和反馈（该文原始得分为 75 分）。可以看出，由于原始作文本身错误较少，在“最小改动”的原则下，进行错误校正以后，作文的错误数量没有发生显著变化，仍存在词语使用不准确和语序不自然的问题。经过大模型的语言简化之后，这些不准确、不自然的地方被纠正，作文的错误数量显著减少，语言表达更加流畅，评分从错误校正后的 80 分升到了 85 分。

作文内容	反馈内容
原始作文：我们的日常生活中听到很多种声音，其中有好听的，有不好听的，比如建筑工程时，汽车的喇叭是很刺耳的，相反鸟声，流水声是很好听，而且令人感到舒服。\n 我关于用自然之声取代噪声的建议完全同义，……如果汽车喇叭声都那么可爱，我们很高兴地让路，而且自己开车的时候，特别是堵车时我们发啤气的状况也可能越来越少。\n 我们去看朋友时，我们常常感觉到他家门的铃声有时很刺耳，我觉得把这个铃声换自然之声更好，比如，鸟声或着几句的话“欢迎”这样的话，家人可能很高兴，自己听的时候也很舒服。\n ……	**语言准确性反馈：** **汉字使用总体正确，但存在个别错误**，例如“发啤气”应为“发脾气”，“完全同义”应为“完全同意”。…… **语言复杂性反馈：** 词汇量较为有限，缺乏丰富的表达方式，例如“鸟声”“流水声”等词语重复使用，建议尝试使用更多同义词或近义词，如“鸟鸣”“潺潺流水”等。……此外，缺乏修辞手段的运用，建议尝试使用比喻、排比等修辞方式增强语言表现力。
错误校正：我们的日常生活中听到很多种声音，其中有好听的，有不好听的，比如建筑工程时，汽车的喇叭是很刺耳的，相反鸟声，流水声是很好听，而且令人感到舒服。 \n 我关于用自然之声取代噪声的建议完全同意，……如果汽车喇叭声都那么可爱，我们很高兴地让路，而且自己开车的时候，特	**语言准确性反馈：** **汉字使用总体正确，但存在个别错误。**例如“鸟声或着几句的话”中的“或着”应为“或者”。词汇使用基本准确，但有些地方表达不够精确，例如“我们很高兴地让路”可以改为“我们会愉快地让路”，以使表达更自然。……**语法方面，句子结构基本正确，但**

别是堵车时我们发脾气的状况也可能越来越少。\n 我们去看朋友时，我们常常感觉到他家门的铃声有时很刺耳，我觉得把这个铃声换自然之声更好，比如，鸟声或着几句的话“欢迎”这样的话，家人可能很高兴，自己听的时候也很舒服。\n ……	**有些句子语序不够自然**，例如“我关于用自然之声取代噪声的建议完全同意”可以改为“我完全同意关于用自然之声取代噪声的建议”。
语言简化：我们的生活里有很多声音，有的好听，有的不好听。比如，建筑工地的声音和汽车喇叭声很吵，相反，鸟叫声和流水声很好听，让人觉得舒服。\n 我很同意用自然的声音代替噪音。……如果汽车喇叭声变得可爱，我们会更愿意让路。开车时，特别是堵车时，我们可能也不会那么容易生气了。\n 去朋友家时，有时候会听到门铃声很刺耳。我觉得可以把门铃换成自然的声音，比如鸟叫声，或者说几句“欢迎”的话。这样家人听了会开心，自己听了也觉得舒服。\n ……	**语言复杂性反馈：** **词汇量较丰富，但可以增加一些更高级的词汇或成语来增强表达效果**，例如使用“悦耳” 替代“好听”。**句式以简单句为主，偶尔使用复句**，如因果关系的句子“如果汽车喇叭声变得可爱，我们会更愿意让路”。可以尝试更多的句式变化，如使用转折句或并列句来增加语言的层次感。

2. 篇章组织水平干预反馈示例

这是一篇题为《我看流行歌曲》的作文在错误校正和篇章组织水平干预前后的内容和反馈（该文原始得分为 55 分）。可以看出，这篇作文本身就存在较为严重的篇章组织问题。由于错误校正并不会处理篇章组织问题，因此当进一步对作文中的句子进行换序，作文的篇章组织水平将一直保持在较低水平，进而导致大模型在反馈中无法识别干预造成的变化，即反馈中对“篇章组织水平” 的描述在干预前后没有体现出显著变化。以这篇作文为例，错误校正后得分为 60 分，段内句子换序后降至 55 分，文内句子换序后仍为 60 分，变化幅度分别为−5 分和 0 分，明显小于表 4 所示的平均水平（−6.89 分和−10.61 分）。

作文内容	反馈内容
错误校正：你认为流得歌曲是什么？我们把什么样的歌曲叫流行歌曲？一般人认为流行歌曲是很多人都喜欢听喜欢唱的就是流行歌曲，但是实际上人们喜欢的，流行的那些流行歌曲是值得喜欢、值得流行的吗？\n 随着文化发展歌曲、歌手的数量也变大了。现在市场上能看到的歌手和他们的专辑已经成千上万了。当然有的歌手和他的歌曲没有受到人们的关注就消逝了。……甚至有的人没有自己的想法就看因特网排第一的就以为最好听的歌曲。但排行也不一定可靠，有的排行顺序是自己随便写的。	**篇章组织水平反馈：** **整体结构不够完整，开头未明确点明主题，仅提出问题但未清晰表达自己的观点。正文部分论述较为零散，缺乏条理性**，例如“现在市场上能看到的歌手和他们的专辑已经成千上万了”与后文“什么样的歌曲能够留下”之间缺乏自然的过渡。**结尾部分未对全文进行总结，文章结束得较为突然。段落之间的逻辑关系不够清晰，关联词使用较少**，例如“甚至有的人没有自己的想法就看因特网排第一的就以为最好听的歌曲”可以通过添加关联词如“因此”来增强逻辑性。
段内句子换序：我们把什么样的歌曲叫流行歌曲？你认为流得歌曲是什么？一般人认为流行歌曲是很多人都喜欢听喜欢唱的就是流行歌曲，但是实际上	**篇章组织水平反馈：** **整体结构不够完整，开头未明确点明主题，仅提出问题但未清晰表达自己的观点。正文部分论述较为**

人们喜欢的，流行的那些流行歌曲是值得喜欢、值得流行的吗？\n 那么，什么样的歌曲能够留下，受到人们的欢迎呢？甚至有的人没有自己的想法就看因特网排第一的就以为最好听的歌曲。随着文化发展歌曲、歌手的数量也变大了。……因为现代的年轻人都以那些广告和宣传比较比较新出现的歌曲。现在市场上能看到的歌手和他们的专辑已经成千上万了。	**零散，缺乏条理性**，例如“现在市场上能看到的歌手和他们的专辑已经成千上万了”与后文“什么样的歌曲能够留下”之间缺乏自然的过渡。**结尾部分未对全文进行总结，文章结束得较为突然。段落之间的逻辑关系不够清晰，关联词使用较少**，例如“甚至有的人没有自己的想法就看因特网排第一的就以为最好听的歌曲”可以通过添加关联词如“因此”来增强逻辑性。
文内句子换序：你认为流得歌曲是什么？但排行也不一定可靠，有的排行顺序是自己随便写的。我们把什么样的歌曲叫流行歌曲？\n 一般人认为流行歌曲是很多人都喜欢听喜欢唱的就是流行歌曲，但是实际上人们喜欢的，流行的那些流行歌曲是值得喜欢、值得流行的吗？现在市场上能看到的歌手和他们的专辑已经成千上万了。……随着文化发展歌曲、歌手的数量也变大了。当然有的歌手和他的歌曲没有受到人们的关注就消逝了。因为现代的年轻人都以那些广告和宣传比较比较新出现的歌曲。我觉得在天天像洪水一样新出现的歌曲当中不广告不宣传会淘汰看不到阳光就消失。	**篇章组织水平反馈：** **作文的整体结构不够完整，缺乏明确的开头和结尾。开头没有清晰地引入主题，正文部分的论述不够充分，缺乏具体的例子和分析。结尾没有对主题进行总结。条理不够清晰，句子之间的连接不够顺畅，段落之间的过渡也不够自然。可以通过使用关联词和过渡语来增强逻辑关系**，例如在段落之间使用“此外”、“因此”等词语。